

# Formula di campionamento di Ewens e applicazioni allo studio della biodiversità delle popolazioni

**Gianluca Covini**

**Relatore:**

Prof. Emanuele Dolera



UNIVERSITÀ  
DI PAVIA

26 Settembre 2022

Indice

- 1 Introduzione
  - 2 Processo di Dirichlet
  - 3 Formula di Ewens
    - Caso base:  $n=2$
    - Caso generico: costruzione diretta
    - Costruzione ricorsiva
    - Metodo Monte Carlo
  - 4 Modello di Wright-Fisher
  - 5 Conclusioni e orizzonti

## Introduzione

*"La formula di campionamento di Ewens esemplifica l'armonia della teoria matematica, dell'applicazione statistica e della scoperta scientifica". H. Crane*

## The Sampling Theory of Selectively Neutral Alleles\*

W. J. EWENS<sup>†</sup>

*Department of Zoology, University of Texas at Austin, Austin, Texas, 78712*

## Problema di Fisher-Corbet-Williams

[ 42 ]

# THE RELATION BETWEEN THE NUMBER OF SPECIES AND THE NUMBER OF INDIVIDUALS IN A RANDOM SAMPLE OF AN ANIMAL POPULATION

By R. A. FISHER (*Galton Laboratory*), A. STEVEN CORBET (*British Museum, Natural History*)  
AND C. B. WILLIAMS (*Rothamsted Experimental Station*)

**Problema statistico:** lo spazio campionario  $\mathbb{X}_1$  a priori non è noto.

## Partizioni casuali

**Idea:** traduco i dati in struttura di partizione

Partizioni di  $\{a, b, c\}$ :

$$\{a, b, c\}; \{a, b\}, \{c\}; \{a, c\}, \{b\}; \{b, c\}, \{a\}; \{a\}, \{b\}, \{c\}$$

$$x_1, \dots, x_n \in \mathbb{X}_1 \rightarrow \{1, \dots, n\}$$

**Strumento:** Formula di campionamento di Ewens, una distribuzione di probabilità sulla classe delle partizioni

# Variabili aleatorie scambiabili

## Scambiabilità

Le v.a.  $X_i : \Omega \rightarrow [a, b]$ ,  $i = 1, 2, \dots$  sono **scambiabili** se

$$P[X_1 \in A_1, \dots, X_n \in A_n] = P[X_1 \in A_{\sigma(1)}, \dots, X_n \in A_{\sigma(n)}]$$

$$\forall n \in \mathbb{N}, \quad \forall \sigma \in S^n, \quad \forall A_1, \dots, A_n \in \mathcal{B}([a, b])$$

# Teorema di De Finetti

Sia  $\mathbb{P}$  lo spazio delle misure di probabilità su  $([a, b], \mathcal{B}([a, b]))$ .

## Teorema (di rappresentazione di De Finetti)

$\{X_i\}_{i \geq 1}$  rappresenta una successione di variabili aleatorie scambiabili se e solo se esiste un'unica m.d.p.  $\mu : \Omega \rightarrow \mathbb{P}$  t.c.

$$P[X_1 \in A_1, \dots, X_n \in A_n] = \mathbb{E}[\mu(A_1) \dots \mu(A_n)]$$

$$\forall A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$$

# Processo di Dirichlet

## Processo di Dirichlet

Sia  $\alpha$  una misura finita su  $[a, b]$  e  $\theta = \alpha([a, b])$ . Il **processo di Dirichlet**  $\mu$  si definisce tramite la densità di Dirichlet, ovvero dati  $C_1, \dots, C_n$  partizione di  $[a, b]$

$$q(\{(\mu(C_1), \dots, \mu(C_{n-1})) \in R\})$$

$$= \int_R \frac{\Gamma(\theta)}{\prod_{i=1}^n \Gamma(\alpha_i)} z_1^{\alpha_1-1} z_2^{\alpha_2-1} \dots z_{n-1}^{\alpha_{n-1}-1} (1 - \sum_{i=1}^{n-1} z_i)^{\alpha_n-1} dz$$

con  $R \in \mathcal{B}(\Delta_{n-1})$ ,  $\alpha_i = \alpha(C_i)$ .

Caso base: n=2

Caso  $n = 2$ 

**Obiettivo:** formula per la probabilità delle partizioni di  $\{1, 2\}$  corrispondenti alle partizioni di variabili aleatorie  $\{X_1 = X_2\}$  e  $\{X_1 \neq X_2\}$ .

- Calcoliamo  $P[X_1 \in A_1, X_2 \in A_2]$  per  $A_1, A_2 \in \mathcal{B}([a, b])$
- Deduciamo da  $P[X_1 \in A_1, X_2 \in A_2]$  il valore di  $P[X_1 = X_2]$

Caso base: n=2

# Legge di probabilità

## Legge di probabilità

$$\begin{aligned} P[X_1 \in A_1, X_2 \in A_2] &= \mathbb{E}[\mu(A_1)\mu(A_2)] \\ &= \gamma\bar{\alpha}(A_1)\bar{\alpha}(A_2) + (1 - \gamma)\bar{\alpha}(A_1 \cap A_2) \end{aligned}$$

Dove  $\bar{\alpha}$  è la misura  $\alpha$  normalizzata e  $\gamma = \theta/(\theta + 1)$ .

Caso base: n=2

# Legge di probabilità

## Legge di probabilità

$$\begin{aligned} P[X_1 \in A_1, X_2 \in A_2] &= \mathbb{E}[\mu(A_1)\mu(A_2)] \\ &= \gamma\bar{\alpha}(A_1)\bar{\alpha}(A_2) + (1 - \gamma)\bar{\alpha}(A_1 \cap A_2) \end{aligned}$$

Dove  $\bar{\alpha}$  è la misura  $\alpha$  normalizzata e  $\gamma = \theta/(\theta + 1)$ .

## Formula di Ewens con $n = 2$

$$P[\Pi_2 = \{1, 2\}] = P[X_1 = X_2] = 1 - \gamma = \frac{1}{\theta + 1}$$

$$P[\Pi_2 = \{1\}, \{2\}] = P[X_1 \neq X_2] = \gamma = \frac{\theta}{\theta + 1}$$

Caso generico: costruzione diretta

# Caso generico

Deduciamo  $P[X_1 \in A_1, X_2 \in A_2, \dots, X_n \in A_n]$  tramite il processo di Dirichlet.

## Legge di probabilità generica

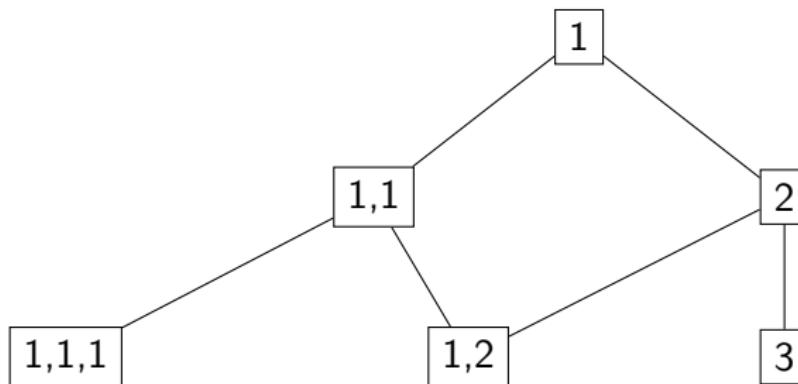
$$P[X_1 \in A_1, \dots, X_n \in A_n] = \sum_{B \in \mathcal{P}_n} w_B \prod_{i=1}^{|B|} \bar{\alpha}\left(\bigcap_{j \in B_i} A_j\right)$$

Con  $B = (B_1, \dots, B_k) \in \mathcal{P}_n$ , insieme delle partizioni di  $\{1, \dots, n\}$ .

La formula di Ewens è la seguente:

$$P[\Pi_n = B] = w_B = \frac{\theta^{|B|}}{(\theta)_n} \uparrow \prod_{i=1}^{|B|} (\#B_j - 1)!$$

# Processo del ristorante cinese



- $\theta/(\theta + n - 1)$ : probabilità che l' $n$ -esimo cliente occupi un tavolo vuoto;
- $n_i/(\theta + n - 1)$ : probabilità che l' $n$ -esimo cliente si sieda in un tavolo occupato già da  $n_i$  commensali.

# Numero di insiemi della partizione

## Probabilità di avere $k$ insiemi

$\gamma_k^{(n)}$  è la probabilità di avere  $k$  insiemi in una partizione di  $\{1, \dots, n\}$ .

$$\gamma_k^{(n)} = \frac{|s(n, k)|\theta^k}{(\theta)_{(n)\uparrow}}$$

Per i numeri di Stirling  $|s(n, k)|$  vale la seguente formula:

$$(\theta)_{n\uparrow} = \theta(\theta + 1) \dots (\theta + n - 1) = \sum_{k=1}^n |s(n, k)|\theta^k$$

# Cardinalità degli insiemi della partizione

Siano  $(n_1, \dots, n_k)$  tali che  $n_1 \leq n_2 \leq \dots \leq n_k$  e  $\sum_{j=1}^k n_j = n$ .

## Probabilità delle cardinalità degli insiemi

$\Gamma_k^{(n)}(n_1, \dots, n_k)$  è la probabilità che gli insiemi della partizione abbiano cardinalità  $n_1, \dots, n_k$ .

$$\Gamma_k^{(n)}(n_1, \dots, n_k) = \frac{n!}{|s(n, k)|} \frac{1}{\prod_{i=1}^k n_i \prod_{j=1}^n m_j!}$$

Con  $m_j = \sum_{i=1}^k \mathbb{1}_{n_i=j}$

# Probabilità di una data partizione

## Probabilità della partizione

Fissati  $k$  e  $(n_1, \dots, n_k)$ , la partizione è scelta con probabilità uniforme  $1/P_k^{(n)}(n_1, \dots, n_k)$ .

$$P_k^{(n)}(n_1, \dots, n_k) = \binom{n}{n_1 \dots n_k} \frac{1}{\prod_{j=1}^n m_j!}$$

# Formula di campionamento di Ewens

## Teorema (formula di Ewens)

$$\text{Ewens}^{(n)}(n_1, \dots, n_k; \theta) = P[\Pi_n = B_1, \dots, B_k] = \frac{\theta^k}{(\theta)_{n \uparrow}} \prod_{j=1}^k (n_j - 1)!$$

Dove  $n_j = \#B_j$ .

## Metodo Monte Carlo

## Metodo Monte Carlo

Partizioni	Frequenza relativa	Valore atteso teorico
{1, 3}, {2}, {4}, {5}	0.0221	0.0222
{1, 2}, {3}, {4}, {5}	0.0215	0.0222
{1}, {2, 3, 4, 5}	0.0325	0.0333
{1}, {2}, {3}, {4}, {5}	0.0408	0.0444
{1, 5}, {2}, {3}, {4}	0.0231	0.0222
...	...	...

Metodo Monte Carlo

# Metodo Monte Carlo

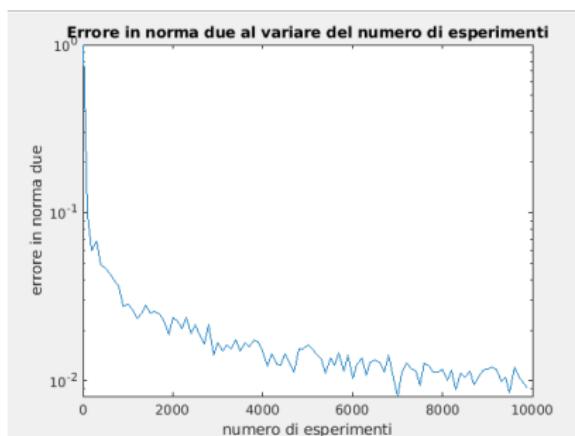
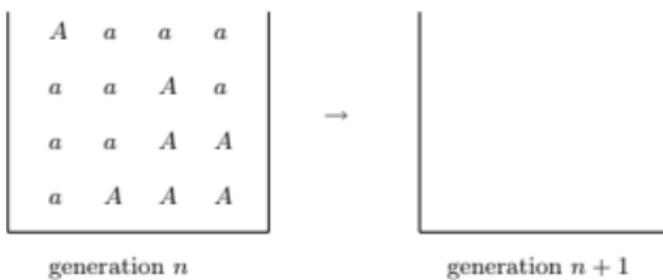


Figure: Errore metodo Monte Carlo

# Modello di Wright-Fisher

## Modello di Wright-Fisher

Dato un locus genico, il **modello di Wright-Fisher** studia la distribuzione degli alleli per il locus in una popolazione diploide di dimensione  $N$  con generazioni non sovrapponibili e accoppiamenti casuali.



# Modello a infiniti alleli

Supponiamo che avvengano mutazioni con tasso  $\mu$  e sia  $\theta = 4N\mu$ .

## Ipotesi

Ogni mutazione genera un allele di un tipo non ancora registrato

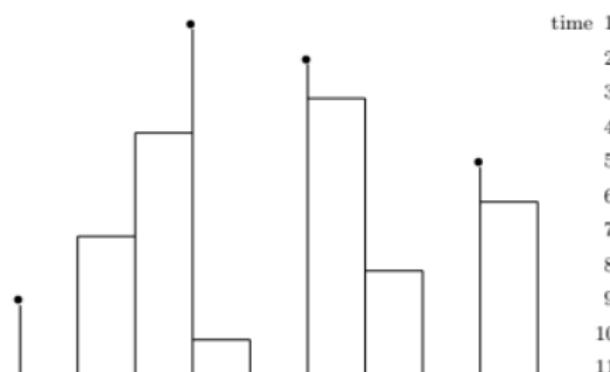
## Partizione allelica

$(m_1, \dots, m_n)$  è una **partizione allelica** se  $m_j$  indica il numero di alleli che appaiono in  $j$  individui.

# Modello a infiniti alleli

## Teorema

La relazione genealogica tra  $k$  lignaggi nel modello a infiniti alleli può essere simulata attraverso un processo del ristorante cinese con  $k$  clienti.



# Formula di campionamento di Ewens

Data  $(m_1, \dots, m_n)$  una partizione allelica e  $\theta = 4N\mu$  tasso di mutazione scalato, allora la probabilità di ogni partizione allelica in un campione di  $n$  elementi è la seguente

## Formula di campionamento di Ewens

$$p(m_1, \dots, m_n; \theta) = \frac{n!}{(\theta)_{(n)\uparrow}} \prod_{j=1}^n \frac{\theta^{m_j}}{j^{m_j} m_j!}$$

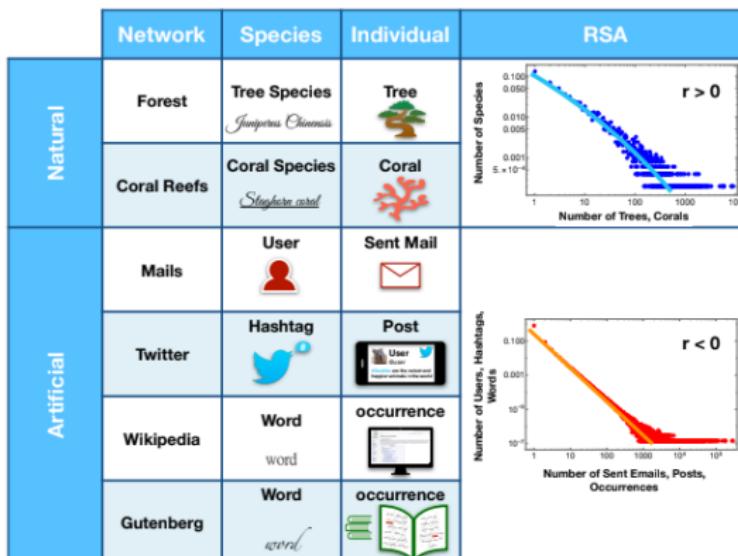
# Conclusioni

- Problema di Fisher-Corbet-Williams
- Ridefinizione del problema in termini di partizioni
- Formula di campionamento di Ewens per la probabilità delle partizioni

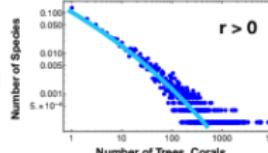
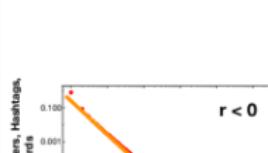
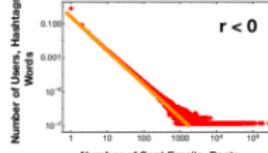
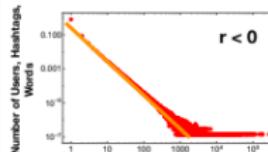
# Linguistica e biodiversità

Upscaling human activity data: an ecological perspective

Anna Tovo <sup>\*a,b</sup>, Samuele Stivanello <sup>†a</sup>, Amos Maritan<sup>b</sup>, Samir Suweis<sup>b,d</sup>, Stefano Favaro <sup>‡c</sup>, and Marco Formentin <sup>§a,d</sup>



Linguistica e biodiversità

	Network	Species	Individual	RSA
Natural	Forest	Tree Species <i>Juniperus chinensis</i>		
	Coral Reefs	Coral Species <i>Scleractinia coral</i>		
Artificial	Mails	User		
	Twitter	Hashtag		
	Wikipedia	Word word		
	Gutenberg	Word		

*"Intraprendere azioni efficaci ed immediate per ridurre il degrado degli ambienti naturali, arrestare la distruzione della biodiversità"*, ONU, Agenda 2030